Trabalho_Final_ML_Cludia_Matheus

July 23, 2019

1 Trabalho prático: Machine Learning I

1.1 Claudia Oliveira; Matheus Reck de Oliveira

Neste trabalho, avaliamos um dataset com classificações de tipos predominantes de área florestal do **Roosevelt National Forest**, no norte do Colorado, nos Estados Unidos. Apresentamos uma análise exploratória do dataset, e avaliamos algoritmos para predição de cobertura de área florestal de segmentos de 30m x 30m da área do parque.

```
In [1]: import pandas as pd
    import matplotlib.pyplot as plt
    from sklearn.model_selection import cross_val_score
    pd.set_option('display.max_columns', 100)
```

1.2 Análise Exploratória

1.2.1 Amostra dos Dados

```
In [2]: dataset = pd.read_csv('C:/dev/PosUniritter/MachineLearning/Uniritter-ML_1_TrabalhoPrat
        # seta as variaveis que possuem os dados do dataset para o treinamento de todos os mod
        X = dataset.drop(['Cover_Type'], axis=1)
        y = dataset['Cover_Type']
        # Início da Analise exploratória do dataset
        print(dataset.head())
   Elevation
              Aspect
                      Slope
                             Horizontal_Distance_To_Hydrology \
        2596
0
                  51
                           3
                                                            258
1
        2804
                 139
                           9
                                                            268
2
        2785
                 155
                          18
                                                            242
3
                           2
        2595
                  45
                                                            153
4
                           6
                                                            300
        2579
                 132
   Vertical_Distance_To_Hydrology
                                    Horizontal_Distance_To_Roadways
0
                                                                  510
                                 0
1
                                65
                                                                3180
```

```
3
                                                                     391
                                  -1
4
                                 -15
                                                                      67
   Hillshade_9am Hillshade_Noon Hillshade_3pm \
              221
                               232
                                                148
0
              234
                               238
1
                                                135
2
              238
                               238
                                                122
              220
                               234
                                                150
3
4
              230
                               237
                                                140
   Horizontal_Distance_To_Fire_Points Wilderness_Area1 Wilderness_Area2
0
                                    6279
                                                           1
                                                                              0
1
                                    6121
                                                           1
                                                                              0
2
                                    6211
                                                                              0
3
                                    6172
                                                                              0
4
                                                                              0
                                    6031
   Wilderness_Area3 Wilderness_Area4
                                          Soil_Type1 Soil_Type2
                                                                    Soil_Type3
0
                   0
                                                                              0
1
                   0
                                       0
                                                    0
                                                                 0
                                                                              0
2
                                                                 0
                   0
                                       0
                                                    0
                                                                              0
3
                   0
                                       0
                                                                 0
                                                                              0
4
   Soil_Type4 Soil_Type5
                             Soil_Type6 Soil_Type7
                                                       Soil_Type8 Soil_Type9
0
                          0
                                       0
                                                    0
             0
                                                                              0
             0
                          0
                                       0
                                                    0
                                                                 0
                                                                              0
1
2
                          0
                                                    0
                                                                 0
                                                                              0
             0
                                       0
3
                          0
                                                    0
                                                                 0
                                                                              0
                                       0
4
                                                                              0
                 Soil_Type11
                                                            Soil_Type14
   Soil_Type10
                               Soil_Type12 Soil_Type13
0
                            0
                                          0
                                                         0
              0
                                                                       0
1
                            0
                                          1
                                                        0
2
              0
                            0
                                          0
                                                         0
                                                                       0
3
              0
                                                                       0
                            0
                                                         0
4
                 Soil_Type16 Soil_Type17 Soil_Type18
                                                            Soil_Type19
   Soil_Type15
0
              0
                            0
                                          0
                                                        0
              0
                            0
                                          0
                                                        0
                                                                       0
1
2
              0
                            0
                                          0
                                                         0
                                                                       0
3
              0
                            0
                                          0
                                                         0
                                                                       0
4
   Soil_Type20
                 Soil_Type21
                               Soil_Type22 Soil_Type23
                                                            Soil_Type24
0
                            0
              0
                            0
                                          0
                                                         0
                                                                       0
1
```

```
2
               0
                              0
                                             0
                                                            0
                                                                           0
3
               0
                              0
                                             0
                                                            0
                                                                           0
4
               0
                                                            0
                                                                           0
                                             0
   Soil_Type25
                  Soil_Type26
                                 Soil_Type27
                                                Soil_Type28
                                                               Soil_Type29
0
               0
                              0
                                                                           0
1
                                             0
                                                            0
                                                                           0
2
               0
                              0
                                             0
                                                            0
3
               0
                              0
                                             0
                                                            0
                                                                           1
4
               0
                              0
                                                            0
                                                                           1
                                             0
   Soil_Type30
                  Soil_Type31
                                 Soil_Type32
                                                Soil_Type33
                                                               Soil_Type34
0
               0
                                                                           0
1
                              0
                                             0
                                                            0
2
               1
                              0
                                                            0
                                                                           0
                                             0
3
               0
                                                                           0
                              0
                                             0
                                                            0
4
               0
                                             0
                                                            0
                                                                           0
   Soil_Type35
                  Soil_Type36
                                 Soil_Type37
                                                Soil_Type38
                                                               Soil_Type39
0
               0
                              0
                                             0
1
               0
                              0
                                             0
                                                            0
                                                                           0
2
               0
                              0
                                             0
                                                            0
                                                                           0
               0
                                             0
                                                                           0
3
                              0
                                                            0
4
                  Cover_Type
   Soil_Type40
0
               0
                             2
1
                             2
2
               0
3
               0
                             5
                             2
4
```

1.2.2 Informações Estatísticas

```
In [3]: shape = dataset.shape
        print("Total de Linhas e Colunas: ", shape)
        sumario = dataset.describe()
        print("Informações estatisticas do Dataset: ")
        print(sumario)
Total de Linhas e Colunas:
                            (581002, 55)
Informações estatisticas do Dataset:
           Elevation
                             Aspect
                                              Slope \
count
      581002.000000 581002.000000 581002.000000
                         155.657158
                                         14.103702
         2959.371136
mean
          279.980764
                         111.913616
                                           7.488241
std
min
         1859.000000
                           0.000000
                                          0.000000
```

| 25% 50% 75% max | 2809.000000 2996.000000 3163.000000 3858.000000 | 58.000000 127.000000 260.000000 360.000000 | 9.000000 13.000000 18.000000 66.000000 | | |
|------------------------------------|---|--|--|---|---|
| count mean std min 25% 50% 75% max | Horizontal_Dista | nce_To_Hydrology 581002.000000 269.429880 212.549971 0.000000 108.000000 218.000000 384.000000 1397.000000 | Vertical_Distanc | ce_To_Hydrology \ 581002.000000 46.419222 58.295524 -173.000000 7.000000 30.000000 69.000000 601.000000 | |
| count mean std min 25% 50% 75% max | Horizontal_Dista | nce_To_Roadways 581002.000000 2350.165252 1559.257261 0.000000 1106.000000 1997.000000 3328.000000 7117.000000 | Hillshade_9am Hi 581002.000000 5 212.145838 26.769947 0.000000 198.000000 218.000000 231.000000 254.000000 | 11shade_Noon \ 581002.000000 223.318806 19.768789 0.000000 213.000000 226.000000 237.000000 254.000000 | |
| count mean std min 25% 50% 75% max | Hillshade_3pm H 581002.000000 142.528609 38.274526 0.000000 119.000000 143.000000 168.000000 254.000000 | orizontal_Distand | 5e_To_Fire_Points 581002.000000 1980.292908 1324.176031 0.000000 1024.000000 1710.000000 2550.000000 7173.000000 | Wilderness_Area1 581002.000000 0.448869 0.497379 0.000000 0.0000000 1.0000000 1.0000000 | \ |
| count mean std min 25% 50% 75% max | Wilderness_Area2 581002.000000 0.051435 0.220884 0.000000 0.000000 0.000000 1.0000000 Soil_Type2 | 581002.00000 0.43607 0.49589 0.00000 0.00000 1.00000 | 581002.0000 74 0.0636 97 0.2440 90 0.0000 90 0.0000 90 0.0000 90 0.0000 90 1.0000 | 581002.000000 521 0.005217 0.072039 000 0.000000 000 0.000000 000 0.000000 000 0.000000 | \ |
| count mean | 581002.000000 5 0.012952 | 81002.000000 581 0.008298 | 0.021336 | 02.000000 0.002749 | |

| std | 0.113067 | 0.090713 | 0.144500 | 0.052356 | |
|-------|---------------|---------------|---------------|---------------|---|
| min | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| 25% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| 50% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| 75% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| | | | | | |
| max | 1.000000 | 1.000000 | 1.000000 | 1.000000 | |
| | Soil_Type6 | Soil_Type7 | Soil_Type8 | Soil_Type9 | \ |
| count | 581002.000000 | 581002.000000 | 581002.000000 | 581002.000000 | ` |
| | 0.011315 | 0.000181 | 0.000308 | 0.001974 | |
| mean | | | | | |
| std | 0.105768 | 0.013442 | 0.017550 | 0.044388 | |
| min | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| 25% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| 50% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| 75% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| max | 1.000000 | 1.000000 | 1.000000 | 1.000000 | |
| | Soil_Type10 | Soil_Type11 | Soil_Type12 | Soil_Type13 | \ |
| count | 581002.000000 | 581002.000000 | 581002.000000 | 581002.000000 | ` |
| count | 0.056168 | 0.021356 | 0.051585 | 0.030002 | |
| mean | | | | | |
| std | 0.230247 | 0.144569 | 0.221188 | 0.170592 | |
| min | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| 25% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| 50% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| 75% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| max | 1.000000 | 1.000000 | 1.000000 | 1.000000 | |
| | Soil_Type14 | Soil_Type15 | Soil_Type16 | Soil_Type17 | \ |
| count | 581002.000000 | 581002.000000 | 581002.000000 | 581002.000000 | ` |
| mean | 0.001029 | 0.000005 | 0.004897 | 0.005890 | |
| std | 0.032066 | 0.002272 | 0.069805 | 0.076519 | |
| min | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| 25% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| | | | | | |
| 50% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| 75% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| max | 1.000000 | 1.000000 | 1.000000 | 1.000000 | |
| | Soil_Type18 | Soil_Type19 | Soil_Type20 | Soil_Type21 | \ |
| count | 581002.000000 | 581002.000000 | 581002.000000 | 581002.000000 | |
| mean | 0.003268 | 0.006921 | 0.015936 | 0.001442 | |
| std | 0.057077 | 0.082903 | 0.125229 | 0.037951 | |
| min | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| 25% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| 50% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| 75% | 0.000000 | 0.000000 | 0.000000 | 0.000000 | |
| | 1.000000 | 1.000000 | 1.000000 | 1.000000 | |
| max | 1.000000 | 1.000000 | 1.000000 | 1.000000 | |
| | Soil_Type22 | Soil_Type23 | Soil_Type24 | Soil_Type25 | \ |

| count mean std min 25% 50% | 581002.000000 0.057440 0.232682 0.000000 0.000000 0.000000 | 581002.000000 0.099401 0.299200 0.000000 0.000000 0.000000 | 581002.000000 0.036623 0.187834 0.000000 0.000000 | 581002.000000 0.000816 0.028551 0.000000 0.000000 0.000000 | |
|------------------------------------|--|--|--|--|---|
| 75% max | 0.000000 | 0.000000 1.000000 | 0.000000 1.000000 | 0.000000 1.000000 | |
| count mean std min 25% 50% 75% max | Soil_Type26 581002.000000 0.004456 0.066605 0.000000 0.000000 0.000000 1.0000000 | Soil_Type27 581002.000000 0.001869 0.043194 0.000000 0.000000 0.000000 1.0000000 | Soil_Type28 581002.000000 0.001628 0.040318 0.000000 0.000000 0.000000 1.0000000 | Soil_Type29 581002.000000 0.198356 0.398762 0.000000 0.000000 0.000000 1.0000000 | \ |
| count mean std min 25% 50% 75% max | Soil_Type30 581002.000000 0.051928 0.221881 0.000000 0.000000 0.000000 1.000000 | Soil_Type31 581002.000000 0.044175 0.205485 0.000000 0.000000 0.000000 1.0000000 | Soil_Type32 581002.000000 0.090394 0.286745 0.000000 0.000000 0.000000 1.000000 | Soil_Type33 581002.000000 0.077716 0.267724 0.000000 0.000000 0.000000 1.0000000 | \ |
| count mean std min 25% 50% 75% max | Soil_Type34 581002.000000 0.002773 0.052584 0.000000 0.000000 0.000000 1.000000 | Soil_Type35 581002.000000 0.003255 0.056957 0.000000 0.000000 0.000000 1.000000 | Soil_Type36 581002.000000 0.000205 0.014310 0.000000 0.000000 0.000000 1.000000 | Soil_Type37 581002.000000 0.000513 0.022642 0.000000 0.000000 0.000000 1.000000 | |
| count mean std min 25% 50% 75% max | Soil_Type38 581002.000000 0.026802 0.161504 0.000000 0.000000 0.000000 1.000000 | Soil_Type39 581002.000000 0.023762 0.152308 0.000000 0.000000 0.000000 1.000000 | Soil_Type40 581002.000000 0.015060 0.121792 0.000000 0.000000 0.000000 1.000000 | Cover_Type 581002.000000 2.051444 1.396483 1.000000 2.000000 2.000000 7.0000000 | |


Temos uma amostra de 581.002 linhas. Pelo somatório acima, podemos observar que não há nenhuma feature com valores faltantes.


1.2.3 Distribuição de classes

Distribuição da classe **Cover Type** Existem sete tipos classes diferentes de Cover Type (área de cobertura):

- 1. Spruce/Fir
- 2. Lodgepole Pine
- 3. Ponderosa Pine
- 4. Cottonwood/Willow
- 5. Aspen
- 6. Douglas-fir
- 7. Krummholz

Histograma com a distibuicao da classe Cover Type





Pelo histograma acima, percebemos que no dataset utilizado para treino, há uma concentração muito maior de instâncias nas duas primeiras classes de Cover Type. Isto significa que a amostra não está balanceada.

1.3 Algorítmos de classificação

Comparamos o desempenho de três algoritmos diferentes: - Knn - Naive Bayes - Decision Trees Para cada um deles, avaliamos a acurácia com através de Cross Validation. Avaliamos também, quando possível, a busca dos melhores hiper parâmetros através do Grid Search.

1.4 Knn

1.4.1 Treino

O treino foi realizado com os parâmetros default.

1.4.2 Cross Validation

1.4.3 Grid Search

```
gs_results = gs.fit(X,y)
        #gs_results_estimator = gs_results.best_estimator_
        gs_results_params = gs_results.best_params_
        #print("Best KNN Estimator: {}".format(gs_results_estimator))
        print("Melhores parametros para o Knn: {}".format(gs_results_params))
        print("Melhor score do Knn {}".format(gs_results.best_score_))
Fitting 10 folds for each of 16 candidates, totalling 160 fits
[Parallel(n_jobs=-1)]: Using backend LokyBackend with 4 concurrent workers.
[Parallel(n_jobs=-1)]: Done 42 tasks
                                       | elapsed: 14.7min
[Parallel(n_jobs=-1)]: Done 160 out of 160 | elapsed: 99.6min finished
Melhores parâmetros para o Knn: {'metric': 'euclidean', 'n_neighbors': 3, 'weights': 'distance
Melhor score do Knn 0.5723043982636893
1.5 Naive Bayes
Não encontramos hiper parâmetros relevantes para tunagem, por isto, optamos por não realizar o
Grid Search.
```

1.5.1 Treino

1.6 Decision Trees

1.6.1 Treino

In [12]: from sklearn.tree import DecisionTreeClassifier

```
Tree_classifier = DecisionTreeClassifier()
         Tree_classifier.fit(X, y)
Out[12]: DecisionTreeClassifier(class_weight=None, criterion='gini', max_depth=None,
                     max_features=None, max_leaf_nodes=None,
                     min_impurity_decrease=0.0, min_impurity_split=None,
                     min_samples_leaf=1, min_samples_split=2,
                     min_weight_fraction_leaf=0.0, presort=False, random_state=None,
                     splitter='best')
1.6.2 Cross Validation
In [13]: scores = cross_val_score(Tree_classifier, X, y, cv=10, scoring='accuracy')
         print("Acuracia Decision Com CV:",scores.mean())
Acuracia Decision Com CV: 0.5909442027365903
1.6.3 Grid Search
In [14]: # GRID SEARCH PARA O DECISION TREE
         grid_params_tree = {"max_depth": [3, 5, 10],
                       "max_features": [ 3, 5, 10, 15, 20],
                       "min_samples_leaf": [1, 3],
                       "criterion": ["gini", "entropy"]
         # Instantiating Decision Tree classifier
         tree = DecisionTreeClassifier()
         tree_cv = GridSearchCV(tree, grid_params_tree, cv = 10, n_jobs=-1)
         tree_cv.fit(X, y)
         # Print the tuned parameters and score
         print("Melhores parametros para a Decision Tree: {}".format(tree_cv.best_params_))
         print("Melhor score para a Decision Tree {}".format(tree_cv.best_score_))
```

Melhores parâmetros para a Decision Tree: {'criterion': 'gini', 'max_depth': 5, 'max_features' Melhor score para a Decision Tree 0.6597516015435403

1.7 Algorítmo com melhor acurácia

Para os três algorítmos, levando em conta os resultados do **Cross Validation** e também da tunagem utilizando **Grid Search**, os melhores scores de acurácia são os seguintes: - Knn: 57% - Naive Bayes: 44% - Decision Trees: 65%

O melhor algorítmo é o **Decision Trees**

1.8 Aplicando os melhores parâmetros

1.8.1 Cross Validation dos melhores parâmetros

1.8.2 Exportando o modelo

1.9 Predição de instâncias

```
In [21]: to_predict = pd.read_csv('C:/dev/PosUniritter/MachineLearning/Uniritter-ML_1_Trabalho
         pred_cols = list(to_predict.columns.values)
         pred = pd.Series(best_tree_classifier.predict(to_predict[pred_cols]))
         print(pred)
0
     2
1
     2
2
     1
3
     2
4
     2
5
     2
6
     2
7
     3
     4
8
     3
dtype: int64
```